块级评测：面试速记卡（RAG 优化•第 0 步）

> 一句话：**第 0 步不是优化检索，是把评测的"尺子"从文件级换成块级**——因为 RAG 优化改的是块与排序，文件级指标看不见这些变化。 本文所有数字均来自 `python eval/run_eval.py --no-llm`（只走 embedding，不消耗对话额度）。

---

1. 一个类比，讲给面试官听

知识库 = 5 个 txt，切成 **88 个块**。

判分粒度	问的问题	你的分数
文件级 `src@3`	"你答对了哪本书？"	**100%**（永远对）
块级 `chunk_recall@3`	"你答对了第几页哪句话？"	**87.5%**

> **"找对书"和"找到那句话"是两回事。** 只看文件级会误以为完美，实际答不准。

---

2. 第 0 步做了什么（4 件事）

#	动作	说明
1	16 条检索用例补 `gold_chunk`	标注"标准答案的那句话"，如 R012 → `扫地机器人不防水`（直接摘原文，不是我写的答案）
2	新增 3 个块级指标	`chunk_recall@3`、`chunk_recall@5`、`chunk_MRR@5`
3	修 bug：多轮检索查询	原来用"那选哪个型号？"检索（无上下文），改为合并历史用户发言
4	修 bug：topk 失真	原来把 retriever 的 `k=3` 复用于 @5 指标，等于只看了 3 条

附带改动：`chat_model` 改懒加载，跑检索评测不再需要对话模型的 key。

---

3. 四个指标的区别（最常被追问）

指标	定义	当前值	用途
`hit@3`（关键词）	top-3 块的**并集**是否覆盖关键事实	93.8%	资料够不够用来答
`src@3`（文件）	top-3 里有没有**正确文件**	100%	召回方向对不对
`chunk_recall@3`（块）	top-3 里有没有**那句标准答案**	**87.5%**	能不能答准
`chunk_MRR@5`	首个含 gold_chunk 的块排名 r 的 1/r 均值	**0.841**	排序好不好

```
chunk_recall@3 = 含 gold_chunk 的块出现在 top-3 的用例数 / 总用例数
chunk_MRR@5    = mean(1 / rank)；未命中记 0，取值 0~1，越高越好
```

---

4. 这组数字说明了什么（核心结论）

```
chunk_recall@5 = 100%   →  正确的那块，永远能召回到前 5
chunk_recall@3 = 87.5%  →  但只有 87.5% 能挤进前 3
```

问题在"排序"，不在"召回"。

如果只有文件级指标	有了块级指标之后
看到 100%，以为没问题	发现 12.5% 的题"答不准"
先去改 `chunk_size`（白忙）	直接判断"该加 rerank"
改完不知道涨没涨	验收标准：87.5% → 100%

逐条明细（节选）：R005 正确块排第 **5**、R012 排第 **4**、R013 第 2、M001 第 2。

---

5. 面试话术（30 秒，背下来）

> "我原来的评测只到文件级，`src@3` 是 100%，看起来完美。但我给每条用例标注了**标准答案所在的具体句子**，重新测出来块级召回只有 87.5%，而 **recall@5 是 100%。** 这说明正确内容都在前 5，只是排不进前 3——**问题在排序而不是召回**。所以我的下一步不是调 chunk_size，而是加 rerank；验收标准就是 chunk_recall@3 从 87.5% 到 100%。"

---

6. 三个高频追问 + 回答

Q1：这不就是 recall@k 吗?

> "是块级 recall，外加 MRR 看排序。区别在于 gold 不是整段文档，而是**那句关键事实**——这样才能区分'找对文件'和'找对内容'。"

Q2：gold_chunk 怎么标的，会不会主观?

> "直接从知识库原文摘一句，不是我写的答案，判据客观；而且刻意选 10–20 字的短句，避免被 chunk 边界切断造成假阴性。"

Q3：为什么只有 16 条?

> "覆盖了 15 条检索用例 + 1 条多轮，都是高频问题。样本少的局限我认，但足以区分排序问题和召回问题，且每条可人工核对。"

---

7. 能体现"工程严谨性"的三个细节

1. 发现 `k=3` 污染了 `@5` 指标 → 会审查"指标是否真的在测它声称的东西"；
2. 多轮检索要用合并后的查询 → 理解"检索输入 = 这句话 + 上文"；
3. `--no-llm` 只走 embedding，几秒一轮、不烧对话额度 → 成本意识。

---

8. 3 分钟自测

问题	答案
第 0 步改的是代码逻辑还是评测?	评测（判据 + 指标），没动任何检索参数
`src@3` 与 `chunk_recall@3` 差在哪?	文件 vs 具体句子
`recall@5=100%` 但 `recall@3=87.5%` 说明什么?	内容都召回了，输在排序 → 该做 rerank
`chunk_MRR@5=0.841` 越高越好吗?	是（1 = 每次第一个就命中）
这个改动对线上回答有影响吗?	暂时没有，它是测量能力；影响发生在加 rerank 之后